



HACETTEPE ÜNİVERSİTESİ

FEN FAKÜLTESİ

İSTATİSTİK BÖLÜMÜ

2022-2023 GÜZ DÖNEMİ

İST 489 - ZAMAN SERİLERİ ANALİZİ ÖDEVİ

Prof. Dr. Cem KADILAR

Arş. Gör. Dr. Ceren ÜNAL

AKDENİZ

YİĞİT SAÇIK 21936277

YUSUF ZİYA ATEŞ 21935621

İçindekiler

1. ZAMAN SERİSİ TANITIMI.....	3
1.1 Zaman Serisi Verisi:	3
1.2 Özet İstatistikler	3
1.3 Veriyi Zaman Serisi Olarak Tanımlama	3
1.4 Zaman Serisi Grafiği Çizme	3
1.5 Durağanlaştırma işlemi.....	4
2. AYRIŞTIRMA YÖNTEMLERİ.....	4
2.1 Toplamsal Ayrıştırma Yöntemi	4
2.2 Çarpımsal Ayrıştırma Yöntemi	5
3. ZAMAN SERİLERİNDE REGRESYON ANALİZİ.....	6
3.1 Toplamsal Regresyon Analizi	6
3.2 Çarpımsal Regresyon Analizi	7
4. WINTERS ÜSTEL DÜZLEŞTİRME YÖNTEMİ	7
4.1 Toplamsal Winters Üstel Düzleştirme Yöntemi	7
4.2 Çarpımsal Winters Üstel Düzleştirme Yöntemi.....	9
5. BOX JENKINS MODELLERİ	10
5.1 Model-1 : ARIMA(2,1,0)(1,1,0).....	10
5.2 Model-2 : ARIMA(0,1,0)(2,1,0).....	11
6. R KODLARI.....	12
7. KAYNAKÇA	28

1. ZAMAN SERİSİ TANITIMI

1.1 Zaman Serisi Verisi:

Aşağıda bir havayolu şirketinin 1949-1960 yılları arasında aylık yolcu sayılarını görmekteyiz.

Aylar	Ocak	Subat	Mart	Nisan	Mayıs	Haziran	Temmuz	Agustos	Eylul	Ekim	Kasim	Aralık
Yıllar												
1949	112	118	132	129	121	135	148	148	136	119	104	118
1950	115	126	141	135	125	149	170	170	158	133	114	140
1951	145	150	178	163	172	178	199	199	184	162	146	166
1952	171	180	193	181	183	218	230	242	209	191	172	194
1953	196	196	236	235	229	243	264	272	237	211	180	201
1954	204	188	235	227	234	264	302	293	259	229	203	229
1955	242	233	267	269	270	315	364	347	312	274	237	278
1956	284	277	317	313	318	374	413	405	355	306	271	306
1957	315	301	356	348	355	422	465	467	404	347	305	336
1958	340	318	362	348	363	435	491	505	404	359	310	337
1959	360	342	406	396	420	472	548	559	463	407	362	405
1960	417	391	419	461	472	535	622	606	508	461	390	432

1.2 Özet İstatistikler

Min. 1st Qu. Median Mean 3rd Qu. Max.
104.0 180.0 265.5 280.3 360.5 622.0


1949-1960 yıllarında arasında en az yolcu sayısının 104 en fazla yolcu sayısının ise 622 olduğu görülmektedir. Bu yıllar arasında ortalama yolcu sayısı ise 280 kişidir.


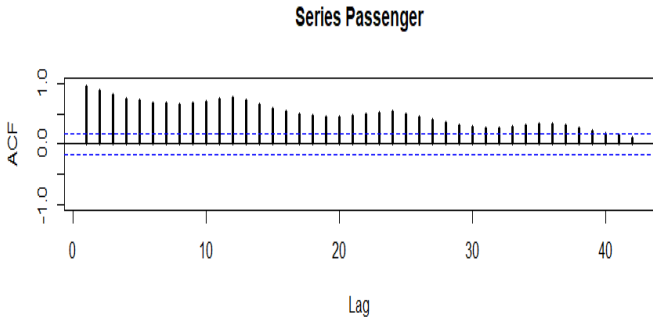
1.3 Veriyi Zaman Serisi Olarak Tanımlama

```
Time Series:
Start = 1
End = 144
Frequency = 1
[1] 112 118 132 129 121 135 148 148 136 119 104 118 115 126 141 135 125 149 170 170 158 133 114 140 145 150
[27] 178 163 172 178 199 199 184 162 146 166 171 180 193 181 183 218 230 242 209 191 172 194 196 196 236 235
[53] 229 243 264 272 237 211 180 201 204 188 235 227 234 264 302 293 259 229 203 229 242 233 267 269 270 315
[79] 364 347 312 274 237 278 284 277 317 313 318 374 413 405 355 306 271 306 315 301 356 348 355 422 465 467
[105] 404 347 305 336 340 318 362 348 363 435 491 505 404 359 310 337 360 342 406 396 420 472 548 559 463 407
[131] 362 405 417 391 419 461 472 535 622 606 508 461 390 432
```

1.4 Zaman Serisi Grafiği Çizme



Yorum: Zaman serisi grafiğine bakarak edindiğimiz önsel bilgi artış ve azalışlar olduğundan dolayı mevsimsellikten şüphe edebileceğizdir.





Yorum: ACF grafiğinde ilk dört gecikmeye baktığımızda güven aralığının dışında olan gözlemler görürüz bu sebeple verimizin trende sahip olduğunu söyleyebiliriz.


1.5 Durağanlaştırma işlemi



Yorum: Verimizi durağanlaştırdık. Periyot 12 olarak bariz bir şekilde gözlemlenmiştir. Mevsimsellik vardır ve baskındır.

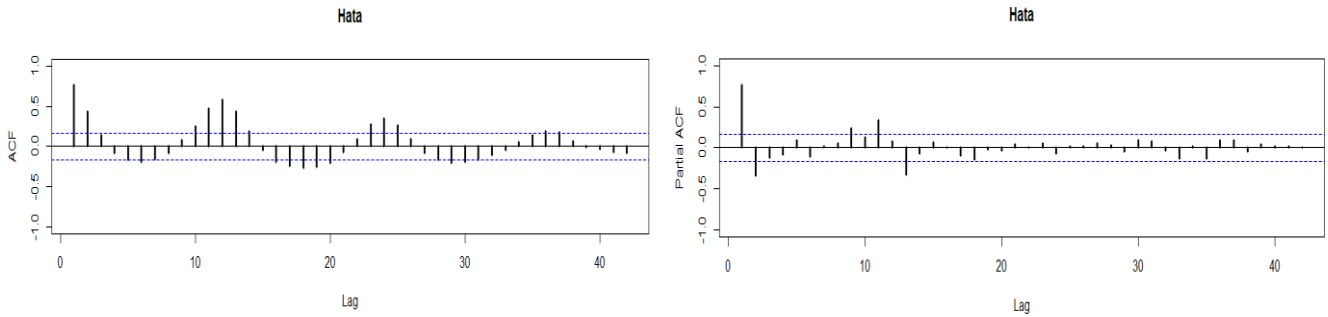
2. AYRIŞTIRMA YÖNTEMLERİ

2.1 Toplamsal Ayrıştırma Yöntemi



Yorum: Tahmin serimiz ve orijinal serimiz birbirine benzediğinden modelin başarılı bir şekilde tahmin edildiğini söyleyebiliriz.

Hatalar Akgürültü müdür?



Yorum: ACF grafiklerine baktığımızda sınır dışında kalan birden fazla değer görmekteyiz. Bu nedenle hataların ak gürültü olmadığından şüpheleniriz.

Box-Ljung Testi


```
> Box.test(hata, lag = 42, type = "Ljung")  
  
Box-Ljung test  
  
data: hata  
X-squared = 408.44, df = 42, p-value < 2.2e-16
```

H_0 : Hatalar arası ilişki yoktur.

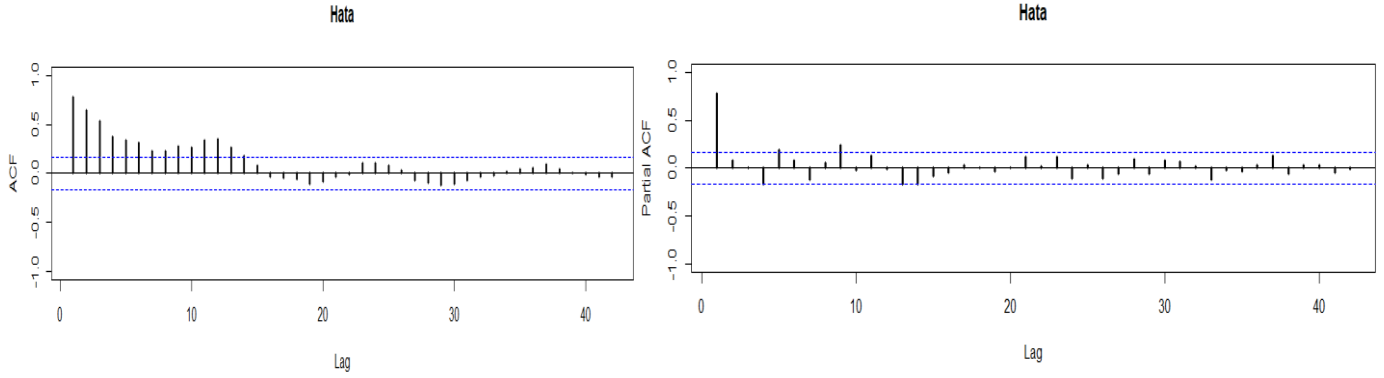
H_S : Hatalar arası ilişki vardır.

Yorum: P değeri < 0.05 olduğundan H_0 hipotezi reddedilir. %95 güven düzeyinde hataların akgürültü serisi olmadığını yani hatalar arasında ilişki olduğunu söyleyebiliriz.

2.2 Çarpımsal Ayrıştırma Yöntemi



Yorum: Orijinal serimiz ile tahmin serisi grafiği birlikte çizildiği zaman uyumlu olduğu görülüyor. Modelin geçerli olduğundan söz edebiliriz



```
> Box.test(hata1, lag = 41, type = "Ljung")

Box-Ljung test

data: hata1
X-squared = 356.12, df = 41, p-value <
2.2e-16
```

Yorum: Toplamsal ve Çarpımsal ayrıştırma yöntemlerinin hata ACF grafikleri ve Box-Ljung testleri dikkate alındığında serilerin akgürültü serisi olmadığı görülür. Bu modeller istatistiksel olarak anlamlı değildir.

3. ZAMAN SERİLERİNDE REGRESYON ANALİZİ

3.1 Toplamsal Regresyon Analizi

```
> summary(regresyonmodeli)

Call:
lm(formula = y ~ t + sin1 + cos1)

Residuals:
    Min       1Q   Median       3Q      Max
-66.068 -22.390  -4.146  17.128 119.986

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  88.18267    5.49402   16.05 < 2e-16 ***
t             2.64988    0.06578   40.29 < 2e-16 ***
sin1        -18.05531    3.86616   -4.67 6.98e-06 ***
cos1        -42.11438    3.85891  -10.91 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 32.74 on 140 degrees of freedom
Multiple R-squared:  0.9271,    Adjusted R-squared:  0.9255
F-statistic: 593.4 on 3 and 140 DF,  p-value: < 2.2e-16

> dwtest(regresyonmodeli)

Durbin-Watson test

data: regresyonmodeli
DW = 0.80565, p-value = 5.348e-14
alternative hypothesis: true autocorrelation is greater than 0
```

H_0 : Model anlamsızdır.

H_5 : Model anlamlıdır.

Yorum: sin1 ve cos1 değerlerinin p değerleri <0.05 olduğu için katsayılarının anlamlı olduğunu söyleyebiliriz. Durbin-Watson test sonucunda p değeri 0,05'ten küçük olduğu için model anlamlıdır.

3.2 Çarpımsal Regresyon Analizi

```
> summary(çarpımsalregresyon)

Call:
lm(formula = y ~ t + s1 + c1)

Residuals:
    Min       1Q   Median       3Q      Max
-63.134 -18.738   1.592  17.698  77.672

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  87.99601    4.48643   19.614 < 2e-16 ***
t             2.64886    0.05374   49.289 < 2e-16 ***
s1           -0.29067    0.03802   -7.644 3.03e-12 ***
c1           -0.56438    0.03756  -15.028 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 26.76 on 140 degrees of freedom
Multiple R-squared:  0.9513,    Adjusted R-squared:  0.9502
F-statistic: 911.1 on 3 and 140 DF,  p-value: < 2.2e-16

> dwtest(çarpımsalregresyon)

Durbin-Watson test

data:  çarpımsalregresyon
DW = 1.0797, p-value = 3.716e-09
alternative hypothesis: true autocorrelation is greater than 0
```

H_0 : Model anlamsızdır.

H_S : Model anlamlıdır.

Yorum: sin1 ve cos1 değerlerinin p değerleri <0.05 olduğu için katsayılarının anlamlı olduğunu söyleyebiliriz. Durbin-Watson test sonucunda p değeri 0,05'ten küçük olduğu için model anlamlıdır.

H_0 reddedilir.

Toplamsal regresyon ve çarpımsal regresyon modellerimiz anlamsız çıktığı için kübik, karesel, üstel ve lojistik regresyonun anlamlı çıkmasını bekleyemeyiz.

4. WINTERS ÜSTEL DÜZLEŞTİRME YÖNTEMİ

4.1 Toplamsal Winters Üstel Düzleştirme Yöntemi

```
> summary(winters1)
ETS(A,A,A)

Call:
ets(y = passengers_ts1, model = "AAA")

Smoothing parameters:
  alpha = 0.9935
  beta  = 2e-04
  gamma = 6e-04


Initial states:
  l = 120.9608
  b = 1.3934
  s = -29.1816 -54.3842 -20.7169 15.0727 65.1554 66.1846
      33.5822 -4.232 -8.0946 -3.8205 -34.3364 -25.2288

sigma: 18.0471

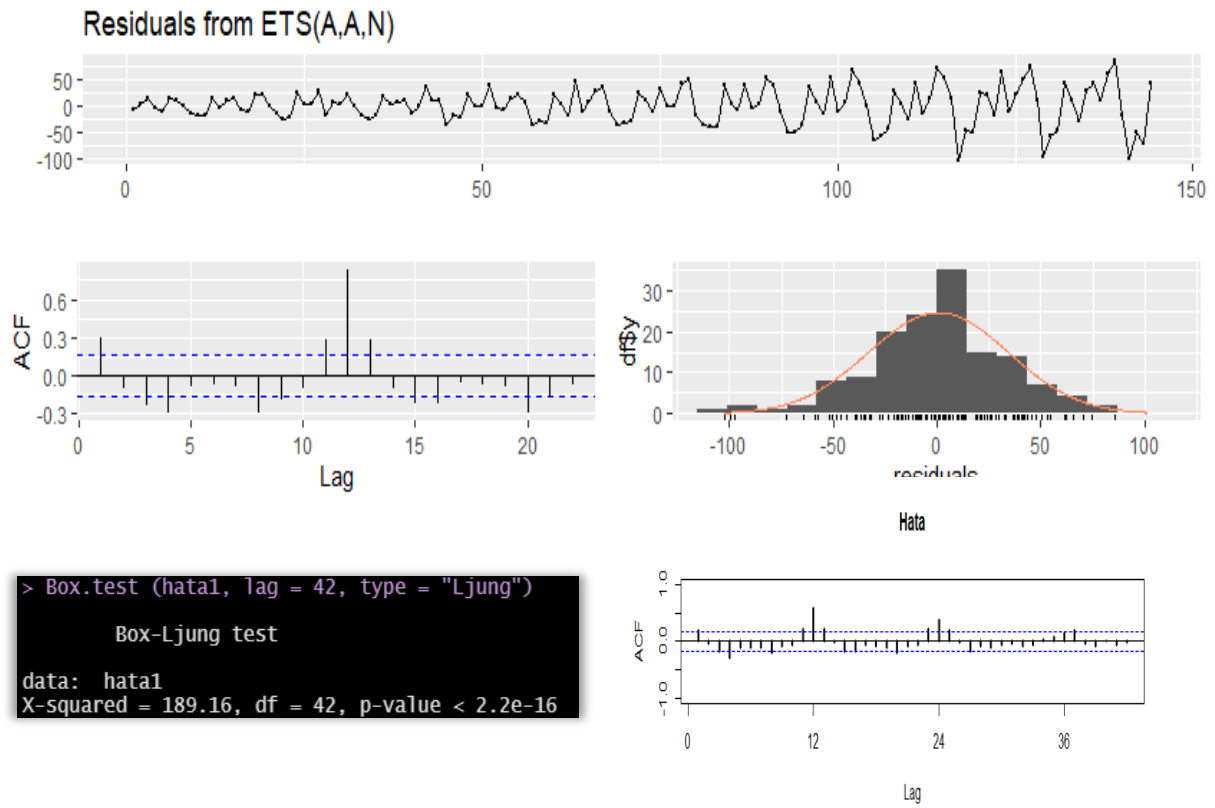
      AIC      AICC      BIC
1565.872 1570.729 1616.359

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.9638247 17.01495 12.81203 0.3539818 5.224715 0.3999971 0.1875311
```

Toplamsal Winters Yöntemi hata kareler ortalamasının karekökü (RMSE) 17.01495'tir. BIC değeri 1616.359'dur.



Orijinal serimiz ile tahmin serisine baktığımızda birbirine yakın değerleri görebiliriz. Tahmin ve orijinal serinin benzerliğinden söz edebiliriz.



Yorum: Çarpımsal Winter Yöntemi istatistiksel olarak %95 güven düzeyinde anlamlıdır. Hata serimizde ACF grafiği incelendiğinde sınır dışı gecikmeler görülür. Bu gecikmelerin önemli olup olmadığını Box-Ljung testiyle görürüz. p-değerleri çok küçük bir değer olduğundan gecikmelerin önemli olmadığını söyleriz. Bu seri modelle çalışılabilir.

4.2 Çarpımsal Winters Üstel Düzleştirme Yöntemi

```
> summary(winters2)
ETS(M,Ad,M)

Call:
ets(y = abs(passengers_ts1), model = "MAM")

Smoothing parameters:
alpha = 0.7096
beta  = 0.0204
gamma = 1e-04
phi   = 0.98


Initial states:
l = 120.9939
b = 1.7705
s = 0.8944 0.7993 0.9217 1.0592 1.2203 1.2318
    1.1105 0.9786 0.9804 1.011 0.8869 0.9059

sigma: 0.0392

      AIC      AICc      BIC
1395.166 1400.638 1448.623

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 1.567359 10.74726 7.791605 0.4357799 2.857917 0.2432573 0.03945056
```


Çarpımsal Winters Yöntemi
hata kareler ortalamasının
karekökü (RMSE)
10.74726'dır. BIC değeri
1448.623'tür.



```
> Box.test(hata2, lag = 42, type = "Ljung")

Box-Ljung test

data: hata2
X-squared = 73.351, df = 42, p-value = 0.001954
```



Yorum: Hataların akgürültü olduğunu ve bu modelin anlamlı olduğunu %95 güven düzeyinde söyleyebiliriz. Toplamsal winters ve çarpımsal winters modellerimizin ikisi de anlamlıdır. Bu yüzden BIC değeri düşük olan yöntemi seçeriz, seçeceğimiz model 1448.623 değerini alan çarpımsal modeldir.

5. BOX JENKINS MODELLERİ

5.1 Model-1 : ARIMA(2,1,0)(1,1,0)

ARIMA (p,d,q) (P,D,Q) d=1, D=1, q=0 , p=2, P=1, Q=0

```
> coeftest(data_arima1)

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ar1   -0.300168   0.087421  -3.4336 0.0005956 ***
ar2   -0.012577   0.088677  -0.1418 0.8872178
sar1  -0.140923   0.098495  -1.4308 0.1524970
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> summary(data_arima1)
Series: passengers_ts
ARIMA(2,1,0)(1,1,0)[12]

Coefficients:
      ar1      ar2      sar1
    -0.3002  -0.0126  -0.1409
s.e.   0.0874   0.0887   0.0985

sigma^2 = 137.8:  log likelihood = -507.19
AIC=1022.37  AICc=1022.69  BIC=1033.87

Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.2941451 11.06892  8.061242 0.04019788 2.85429 0.2516755 -0.003246731
```

Yorum: Ar2 ve sar1 p değerleri 0,05'ten büyük olduğu için önemsizdir. %95 güven düzeyinde model anlamsızdır. Bu nedenle modelin devamı incelenmez.

Şimdi sırada “P” değişkenine 0 verip “Q” değişkenini denemek kalıyor.

5.2 Model-2 : ARIMA(0,1,0)(2,1,0)

ARIMA (p,d,q) (P,D,Q) d=1, D=1, q=0 , p=2, P=1, Q=0

```
> coeftest(data_arima2)
z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ar1  -0.2991886  0.0878628 -3.4052 0.0006612 ***
ar2  -0.0084551  0.0885257 -0.0955 0.9239093
sma1 -0.1035225  0.0836785 -1.2371 0.2160330
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> summary(data_arima2)
Series: passengers_ts
ARIMA(2,1,0)(0,1,1)[12]

Coefficients:
      ar1      ar2      sma1
    -0.2992 -0.0085 -0.1035
s.e.   0.0879  0.0885  0.0837

sigma^2 = 138.5: log likelihood = -507.45
AIC=1022.9  AICC=1023.22  BIC=1034.41

Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.2729692 11.09613 8.103246 0.03609403 2.876587 0.2529869 -0.003017041
```

Yorum: Ar2 ve sma1 p değerleri 0,05'ten büyük olduğu için önemsizdir. %95 güven düzeyinde model anlamsızdır. Bu nedenle diğer modellere bakmaya gerek yoktur.

6. R KODLARI

##Veri Okutma

install.packages("fpp")

install.packages("forecast")

install.packages("haven")

library(fpp)

library(forecast)

library(haven)

library(readxl)

library(readxl)

**zamanserisi <- read_excel("C:/Users/90545/Desktop/Zaman Serisi
Ödevi/zamanserisi.xlsx")**

View(zamanserisi)

passengers<-zamanserisi\$Passengers

summary(passengers)

##Veriyi Zaman Serisi Olarak Tanımlama

passengers_ts <- ts(passengers, frequency=12, start=c(1949,1))

passengers_ts

zamanserisi

##Zaman Serisi Grafiği

plot.ts(passengers_ts,lwd=3, xlab = "Year", ylab = "Number of Passengers")

ACF ve PACF grafikleri

Acf(passengers,main="Series Passenger",lag.max = 42, ylim= c(-1,1),lwd=3)

Pacf(passengers,lag.max = 42, ylim= c(-1,1),lwd=3)

Durağanlaştırma İşlemi

Acf(diff(passengers_ts),main="Series Passenger",lag.max = 42, ylim = c(-1,1),lwd=3)

Pacf(diff(passengers_ts),main="Series Passenger",lag.max = 42,lwd=3)

ap_trend <- tslm(passengers_ts~trend)

periyot <- passengers_ts-ap_trend[["fitted.values"]]

Acf(periyot,lag.max = 42, ylim=c(-1,1), lwd=3)

Pacf(periyot,lag.max = 42, ylim=c(-1,1), lwd=3)

Toplamsal Ayırma İşlemi

Merkezsel Hareketli Ortalama Hesabı

map <- ma(passengers, order= 12, centre = TRUE) # Germe sayısı 12

Mevsim <- passengers-map

ort <- t(matrix(data = Mevsim, nrow = 12, ncol = 12))

ort

colMeans(ort, na.rm = TRUE)

sum(colMeans(ort, na.rm = TRUE))

mean(colMeans(ort, na.rm = TRUE))

endeks<- colMeans(ort, na.rm = T)-mean(colMeans(donemort, na.rm = T))

indeks <- matrix(data = endeks, nrow = 144)

indeks

```
trenthata <- passengers - indeks
```

```
trenthata
```

```
trent <- tslm(ts(trenthata)~trend)
```

```
tahmin <- indeks+trent[["fitted.values"]]
```

```
tahmin
```

```
hata<- ts(passengers)-indeks-trent[["fitted.values"]]
```

```
hata
```

```
### Modelin Güvenilirliği ###
```

```
plot(window(passengers_ts),
```

```
  xlab="Zaman", ylab="", main="Model Güvenirliği" ,lty=1,col=1, lwd=2,  
  ylim=c(19,600))
```

```
lines(window(tahmin), lty=3,col=6,lwd=3)
```

```
legend("topleft", c(expression(paste(Yolcu)),
```

```
expression(paste(Tahmin))),
```

```
lwd = c(2,2), lty = c(1,3), cex = 0.6, col = c(1,6))
```

```
# Hatalar akgürültü mü ?
```

```
Acf(hata, main = "Hata", lag.max = 42, ylim = c(-1,1), lwd = 3)
```

```
Pacf(hata, main = "Hata",lag.max = 42 , ylim = c(-1,1), lwd = 3)
```

```
Box.test(hata, lag = 42, type = "Ljung")
```

```
# Mevsimsel bileşeni bulunması
```

```
mevsim1 <- ts(passengers)/ ts(map)
```

```
# Her bir periyot için ortalama değerlerinin hesabı
```

```
donemort1 <- t(matrix(data = mevsim1, nrow = 12, ncol=12))
```

```
colMeans(donemort1, na.rm = T)
```

```
#toplam
```

```
sum(colMeans(donemort1, na.rm = T))
```

```
#ortalamaların ortalaması
```

```
mean(colMeans(donemort1, na.rm = T))
```

```
#mevsimsel endeks değerlerinin bulunusu
```

```
endeks1<- colMeans(donemort1, na.rm = T)/mean(colMeans(donemort1, na.rm = T))
```

```
mean(endeks1)
```

```
#endeks değerlerini seri boyunca yazdırma işlemi
```

```
indeks1<- matrix(data = endeks1, nrow = 144)
```

```
#trend serisi
```

```
trenthata1 <- ts(passengers) /indeks1
```

```
trenthata1
```

```
#hata dan arindirma islemi
```

```
library(forecast)
```

```
trent1<- tslm(ts(trenthata1)~trend)
```

```
tahmin1<- indeks1*trent1[["fitted.values"]]
```

```
#hata terimi
```

```
hata1<- ts(passengers) - tahmin1
```

```
#orijinal seri ile tahmin serisinin uyumu
```

```
plot( window(passengers_ts),  
xlab="Zaman", ylab="",lty=1, col=1, lwd=2)  
lines( window(tahmin1) ,lty=3,col=6,lwd=3)  
legend("topleft",c(expression(paste(Orjinal )),  
expression(paste(Tahmin ))),  
lwd=c(2,2),lty=c(1,3), cex=0.6, col=c(1,6))
```

```
Box.test(hata, lag = 41, type = "Ljung")
```

```
#hatalar akgurultu mu?
```

```
Acf(hata1,main="Hata", lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
Pacf(hata1,main="Hata",lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
Box.test(hata1, lag = 41, type = "Ljung")
```


Toplamsal Regresyon Modeli

```
t <-1: 1: 144 # t terimini olusturalim
```

```
sin1<-sin(2*3.1416*t/12)
```

```
cos1<-cos(2*3.1416*t/12)
```

```
toplamsalveri <-as.data.frame(cbind(passengers_ts, t, sin1, cos1))
```

```
names(toplamsalveri)<- c("y", "t", "sin1", "cos1")
```

```
attach(toplamsalveri)
```

```
regresyonmodeli<-lm(y~t+sin1+cos1)
```

```
summary(regresyonmodeli)
```

```
dwtest(regresyonmodeli)
```

Çarpımsal Regresyon Modeli

```
s1<-t*sin(2*3.1416*t/12)
```

```
c1<-t*cos(2*3.1416*t/12)
```

```
çarpımveri <-as.data.frame(cbind(passengers_ts, t, s1, c1))
```

```
names(çarpımveri)<- c("y", "t", "s1", "c1")
```

```
attach(çarpımveri)
```

```
çarpımsalregresyon<-lm(y~t+s1+c1)
```

```
summary(çarpımsalregresyon)
```

```
dwtest(çarpımsalregresyon)
```

```
#####
```

```

### Karesel, Kubik, Lojistik ###
### 1. Karesel Regresyon ###
install.packages("Rcmdr", dependencies = TRUE)
install.packages("FitAR")
install.packages("devtools")
library(fpp)
library(stats)
library(forecast)
library(FitAR)
library(haven)
library(devtools)
library(ggplot2)

month = seq(1,144)

#zaman serisi grafiği çizme

ts.plot(passengers_ts,gpars=list(xlab="Month", ylab="Yolcular"))

kareselmodel <- lm(passengers_ts ~ month + I(month^2))

summary(kareselmodel)

kareseltahmin <- predict(kareselmodel) #tahmin serisinin elde edilmesi
kareselsinir <- predict(kareselmodel, interval='confidence',level=0.95) # Güven aralığı
k.altsinir<- (kareselsinir[,2]) # Alt sinir
k.ustsinir<- (kareselsinir[,3]) # Üst sinir
kareselhata<- passengers-kareseltahmin #hata serisi

kareselongoru1 <- predict(kareselmodel, data.frame(month=145))
kareselongoru2 <- predict(kareselmodel, data.frame(month=146))

```

```
kareselongoru3 <- predict(kareselmodel, data.frame(month=147))
```

```
kareselongoru4 <- predict(kareselmodel, data.frame(month=148))
```

```
# Hatalar akgurultu mu?
```

```
Acf(karesel.hata,lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
Pacf(karesel.hata,lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
# H0:hatalar arasında iliski yoktur.
```

```
Box.test (karesel.hata, lag = 42, type = "Ljung")
```

```
#LjungBoxTest(karesel.hata,k=2, StartLag=1, lag=30 )
```

```
plot( window(passengers),
```

```
  xlab="passengers_ts", ylab="",type="l", lty=1, col=4, lwd=2, ylim=c(0,250))
```

```
lines( window(karesel.tahmin) ,lty=3,col=2,lwd=3)
```

```
legend("topleft",c(expression(paste(Veri)),
```

```
  expression(paste(KareselTahmin))),
```

```
  lwd=c(2,2),lty=c(1,3), cex=0.7, col=c(4,2))
```

```
plot( window(passengers_ts), main="Karesel",
```

```
  xlab="passengers_ts", ylab="", type="l", lty=3, col=2, lwd=2, ylim=c(0,550))
```

```
lines(window(k.altsinir) ,type="l",lty=1,col=4,lwd=2)
```

```
lines(window(k.ustsinir) ,type="l",lty=1,col=3,lwd=2)
```

```
legend("topleft",c(expression(paste(Veri)),
```

```
  expression(paste(AltSınır)),
```

```
  expression(paste(ÜstSınır))),
```

```
  lwd=c(2,2,2),lty=c(3,1,1), cex=0.7, col=c(2,4,3))
```

KÜbik Regresyon

```
kubik.model <- lm(formula=passengers_ts ~ month + I(month^2)+ I(month^3))  
summary(kubik.model)
```

```
kubik.tahmin <- predict(kubik.model) # Tahmin serisinin elde edilmesi  
kubik.sinir <- predict(kubik.model, interval='confidence',level=0.95) # Guven araligi  
ku.altsinir<- (kubik.sinir[,2]) #alt sinir  
ku.ustsinir<- (kubik.sinir[,3]) #ust sinir  
kubik.hata<- month-kubik.tahmin #hata serisi
```

```
kubik.ongoru1 <- predict(kubik.model, data.frame(month=145))  
kubik.ongoru2 <- predict(kubik.model, data.frame(month=146))  
kubik.ongoru3 <- predict(kubik.model, data.frame(month=147))  
kubik.ongoru4 <- predict(kubik.model, data.frame(month=148))
```

```
plot( window(passengers_ts),  
xlab="Zaman", ylab="",type="l", lty=1, col=4, lwd=2, ylim=c(55,1200))  
lines( window(kubik.tahmin) ,lty=3,col=2,lwd=3)  
legend("topleft",c(expression(paste(veri)),  
expression(paste(K?bikTahmin))),  
lwd=c(2,2),lty=c(1,3), cex=0.7, col=c(4,2))
```

```
plot( window(passengers_ts), main="Kübik",  
xlab="Zaman", ylab="", type="l", lty=3, col=2, lwd=2, ylim=c(55,1200))  
lines( window(ku.altsinir) ,type="l",lty=1,col=4,lwd=2)  
lines( window(ku.ustsinir) ,type="l",lty=1,col=3,lwd=2)  
legend("topleft",c(expression(paste(data)),  
expression(paste(Altsinir)),  
expression(paste(Üstsinir))),
```

```
lwd=c(2,2,2),lty=c(3,1,1), cex=0.7, col=c(2,4,3))
```

```
#Hatalar akgurultu mu?
```

```
Acf(kubik.hata,lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
Pacf(kubik.hata,lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
Box.test (kubik.hata, lag = 42, type = "Ljung")
```

```
#LjungBoxTest(kubik.hata,k=2, StartLag=1, lag=30 )
```

```
plot( window(passengers_ts),  
xlab="passengers_ts", ylab="",type="l", lty=1, col=4, lwd=2, ylim=c(0,240))  
lines( window(kubik.tahmin) ,lty=3,col=2,lwd=3)  
legend("topleft",c(expression(paste(ap)),  
expression(paste(KübikTahmin))),  
lwd=c(2,2),lty=c(1,3), cex=0.7, col=c(4,2))  
plot( window(month), main="Kübik",  
xlab="passengers_ts", ylab="", type="l", lty=3, col=2, lwd=2, ylim=c(0,240))  
lines( window(ku.altsinir) ,type="l",lty=1,col=4,lwd=2)  
lines( window(ku.ustsinir) ,type="l",lty=1,col=3,lwd=2)  
legend("topleft",c(expression(paste(AP)),  
expression(paste(AltSınır)),  
expression(paste(ÜstSınır))),  
lwd=c(2,2,2),lty=c(3,1,1), cex=0.7, col=c(2,4,3))
```

```
### Lojistik Regresyon ###
```

```
L=700
```

```
seri1<- log((L/month)-1)
```

```
lojistik.model <- lm(seri1 ~ month)
```

```
summary(lojistik.model)
```

```
lojistik.tahmin <- (L/(1+exp(predict(lojistik.model)))) # tahmin serisinin elde edilmesi
```

```
lojistik.sinir <- predict(lojistik.model, interval='confidence',level=0.95) # guven araligi
```

```
l.altsinir<- (L/(1+exp(lojistik.sinir[,2]))) # alt sinir
```

```
l.ustsinir<- (L/(1+exp(lojistik.sinir[,3]))) # ust sinir
```

```
lojistik.hata<- passengers_ts-lojistik.tahmin # hata serisi
```

serinin her donemine denk gelen ongoru degerlerinin elde

```
lojistik.ongoru1 <- (L/(1+exp(predict(lojistik.model, data.frame(month=145)))))
```

```
lojistik.ongoru2 <- (L/(1+exp(predict(lojistik.model, data.frame(month=146)))))
```

```
lojistik.ongoru3 <- (L/(1+exp(predict(lojistik.model, data.frame(month=147)))))
```

```
lojistik.ongoru4 <- (L/(1+exp(predict(lojistik.model, data.frame(month=148)))))
```

#Hatalar akgurultu mu?

```
Acf(lojistik.hata,lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
Pacf(lojistik.hata,lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
Box.test (lojistik.hata, lag = 42, type = "Ljung")
```

```
plot( window(passengers_ts), main="Lojistik Regresyon Grafiği",
```

```
  xlab="Zaman", ylab="", type="l", lty=3, col=1, lwd=2, ylim=c(55,1200))
```

```
lines( window(l.altsinir) ,type="l",lty=1,col=6,lwd=2)
```

```
lines( window(l.ustsinir) ,type="l",lty=1,col=4,lwd=2)
```

```
legend("topleft",c(expression(paste(Veri)),
```

```
expression(paste(Altsınır)),  
expression(paste(Üstsınır))),  
lwd=c(2,2,2),lty=c(3,1,1), cex=0.7, col=c(2,4,3))
```

Üstel Regresyon

```
ustel.model <- lm(log(passengers_ts) ~ month)  
summary(ustel.model)
```

```
ustel.tahmin <- predict(ustel.model) #t ahmin serisinin elde edilmesi  
ustel.tahmin<- exp(ustel.tahmin)
```

```
ustel.sinir <- predict(ustel.model, interval='confidence',level=0.95) #guven araligi  
u.altsinir<- exp(ustel.sinir[,2]) #alt sinir  
u.ustsinir<- exp(ustel.sinir[,3]) #ust sinir  
ustel.hata<- passengers_ts-ustel.tahmin #hata serisi015
```

```
#serinin her donemine denk gelen ongoru degerlerinin elde  
ustel.ongoru1 <- predict(ustel.model, data.frame(month=145))  
ustel.ongoru2 <- predict(ustel.model, data.frame(month=146))  
ustel.ongoru3 <- predict(ustel.model, data.frame(month=147))  
ustel.ongoru4 <- predict(ustel.model, data.frame(month=148))
```

```
plot( window(passengers),  
xlab="Zaman", ylab="",type="l", lty=1, col=4, lwd=2, ylim=c(55,1200))  
lines( window(ustel.tahmin) ,lty=3,col=2,lwd=3)  
legend("topleft",c(expression(paste(veri)),  
expression(paste(LojistikTahmin))),  
lwd=c(2,2),lty=c(1,3), cex=0.7, col=c(4,2))
```

```

plot( window(passengers), main="Ustel",
xlab="Zaman", ylab="", type="l", lty=3, col=2, lwd=2, ylim=c(55,1200))
lines( window(u.altsinir) ,type="l",lty=1,col=4,lwd=2)
lines( window(u.ustsinir) ,type="l",lty=1,col=3,lwd=2)
legend("topleft",c(expression(paste(passengers)),
expression(paste(Altsinir)),
expression(paste(Ustsinir))),
lwd=c(2,2,2),lty=c(3,1,1), cex=0.7, col=c(2,4,3))

```

```
#####
```

```
# TOPLAMSAL WINTERS USTEL DUZLESTIRME YONTEMI
```

```
#AAN=Holt, AAA=Toplamsal Winters, MAM=Çarpımsal Winters
```

```
install.packages("forecast")
```

```
library(forecast)
```

```
passengers_ts1<-ts(passengers,frequency = 12)
```

```
winters1<- ets(passengers_ts1, model = "AAA")
```

```
summary(winters1)
```

```
tahmin1<- winters1[["fitted"]]
```

```
ts.plot(passengers_ts)
```

```
plot( window(passengers_ts1),
```

```
xlab="Zaman", ylab="",lty=1, col=1, lwd=2)
```

```
lines(window(tahmin1) ,lty=3,col=6,lwd=3)
```

```
legend("topleft",c(expression(paste(Orjinalseri)),
```

```
expression(paste(Winters1Tahmin))),
```

```
lwd=c(2,2),lty=c(1,3), cex=0.7, col=c(1,6))
```

```
hata1<- winters1[["residuals"]]
```

```
hata1
```



```
Box.test (hata1, lag = 42, type = "Ljung")
```

```
Acf(hata1,main="Hata", lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
Pacf(hata1,main="Hata",lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
checkresiduals(winters1, lag = 42)
```

```
ongoru4 <- forecast(winters1,h=7)
```

```
ongoru4[["mean"]]
```

```
#model anlamlı çıktığı için öngöründe bulunulmuştur.akgürültü serisi.
```

```
# Wiinters Çarpımsal Düzleştirme
```

```
passengers_ts1<-ts(passengers,frequency = 12)
```

```
winters2 <- ets(abs(passengers_ts1), model = "MAM")
```

```
summary(winters2)
```

```
#BIC = 1448.623
```

```
# ikisi de anlamlı,çarpımsal winters modeli bic değeri küçük olduğundan tercih edilir.
```

```
tahminb<- winters2[["fitted"]]
```

```
plot( window(passengers_ts1),
```

```
  xlab="Zaman", ylab="",lty=1, col=1, lwd=2)
```

```
lines( window(tahminb) ,lty=3,col=6,lwd=3)
```

```
legend("topleft",c(expression(paste(Orjinalseri)),
```

```
  expression(paste(Winters1Tahmin))),
```

```
  lwd=c(2,2),lty=c(1,3), cex=0.7, col=c(1,6))
```

```
hata2<- winters2[["residuals"]]
```

```
Box.test (hata2, lag = 42, type = "Ljung")
```

```
Acf(hata2,main="Hata", lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
Pacf(hata2,main="Hata",lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
checkresiduals(winters2, lag = 42)
```

```
ongoru <- forecast(winters2,h=5)
```

```
ongoru[["mean"]]
```

```
#####BOX JENKINS MODELLERİ#####
```

```
#ARIMA (p,d,q) (P,D,Q) d=0, D=1, q=0 , p=0, P=1, Q=0
```

```
library(forecast)
```

```
Acf(passengers_ts,lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
Pacf(passengers_ts,lag.max = 42, ylim=c(-1,1), lwd=3)
```

```
data_diff <- diff(passengers_ts, 12)
```

```
Acf(data_diff,lag.max = 42,ylim=c(-1,1), lwd=2)
```

```
Pacf(data_diff,lag.max = 42,ylim=c(-1,1), lwd=2)
```

```
#P=1 Q=0
```

```
data_arima1 <- Arima(passengers_ts, order = c(2,1,0), seasonal= c(1,1,0),
```

```
include.constant=TRUE)
```

```
coeftest(data_arima1)
```

```
summary(data_arima1)
```

```
Acf(data_arima1$residuals, ylim=c(-1,1), lwd=3)
```

```
Box.test(data_arima1$residuals, type="Ljung")
```

```
#p değeri alfadan büyük olduğu için model anlamsız bu nedenle
```

```
#modelin devamı incelenmez
```

```
#P=0 Q=1
```

```
data_arima2 <- Arima(passengers_ts, order = c(2,1,0), seasonal= c(0,1,1),
```

```
include.constant=TRUE)
```

```
coeftest(data_arima2)
```

```
summary(data_arima2)
```

```
Acf(data_arima2$residuals, ylim=c(-1,1), lwd=3)
```

```
Box.test(data_arima2$residuals, type="Ljung")
```

```
#Model Anlamalı Çıksaydı Öngörülerin Yapılması
```

```
model <- Arima(passengers, order=c(0,1,0), seasonal=c(2,1,0), include.constant = TRUE)
```

```
ongoru <- forecast(data_arima1, h=5)
```

```
ongoru[['mean']]
```

7. KAYNAKÇA

Spss ve R Uygulamalı Zaman Serileri Analizine Giriş Kitabı (Prof. Dr. Cem Kadılar, Dr. Hatice Öncel Çekim)

<https://www.kaggle.com/datasets/chirag19/air-passengers>

<https://www.statmethods.net/advstats/timeseries.html>

<https://a-little-book-of-r-for-time-series.readthedocs.io/en/latest/src/timeseries.html>

<https://medium.com/@ashnumpy/r-ile-mevsimsel-zaman-serilerinde-box-jenkins-modelleri-f2c3f4a7cbd>

http://rstudio-pubs-static.s3.amazonaws.com/311446_08b00d63cc794e158b1f4763eb70d43a.html

<https://stat-wizards.github.io/Forecasting-A-Time-Series-Stock-Market-Data/>